Imię i Nazwisko: Jakub Gronkiewicz	**Kierunek:** IAD	**PUNKTACJA**
Prowadzący: AK	**Numer albumu:** 338989	/ 12

Raport z Kamienia Milowego 1: Eksploracja i przygotowanie danych

1 Eksploracyjna analiza danych

W ramach eksploracyjnej analizy danych (EDA) zbadano strukturę dostarczonego zbioru, ze szczególnym uwzględnieniem rozkładów, braków danych oraz potencjalnych anomalii. Zmienna docelowa wykazuje wyraźne niezbalansowanie – klasa pozytywna czyli klienci, którzy nie wywiązali się ze spłaty stanowi 21,58% całego zbioru.

1.1 Identyfikacja braków danych i wartości odstających

Analiza statystyk opisowych ujawniła następujące usterki wymagające systemowej obsługi w piplineie:

- **Jawne braki danych (NaN):** Zmienne `PAY_5`, `BILL_AMT6` oraz `PAY_AMT4` posiadają blisko 10% brakujących obserwacji, co wymusi wdrożenie metod imputacji.
- **Anomalie finansowe:** Zidentyfikowano wartości nielogiczne z biznesowego punktu widzenia, w tym ujemny limit kredytowy (`LIMIT_BAL` = -157.51), ujemne wartości wpłat własnych oraz ekstremalnie ujemne salda wyciągów (np. `BILL_AMT6` sięgające -233 709).

1.2 Korelacje i rozkłady

Wizualizacja macierzy korelacji ujawniła ekstremalnie silną współliniowość w obrębie kwot wyciągów (`BILL_AMT1` do `BILL_AMT6`). Najwyższą moc predykcyjną względem ryzyka kredytowego niosą historyczne statusy opóźnień (najsilniej `PAY_0`). Rozkłady zmiennych numerycznych okazały się mocno prawoskośne, jednak obrany na tym etapie algorytm drzewa decyzyjnego jest niewrażliwy na wartości odstające i nie wymaga transformacji logarytmicznych.

2 Metryka ewaluacji, podział danych i modelowanie

Zbiór danych podzielono na część treningową oraz testową przy wykorzystaniu parametru stratify, co pozwoliło zachować oryginalną proporcję dłużników.

2.1 Wybór metryk i optymalizacja hiperparametrów

Główną metryką optymalizacji w przeszukiwaniu siatki uczyniono obszar pod krzywą ROC, która weryfikuje zdolność algorytmu do poprawnego rankowania klientów ryzyka. Jako miarę pomocniczą wyznaczono **Average Precisio**, bezwzględniej oceniającą precyzję detekcji samych dłużników. Strojenie drzewa decyzyjnego wyłoniło parametry optymalne: `max_depth = 12` oraz `min_samples_leaf = 90`. Wymóg wysokiej liczby obserwacji w liściu skutecznie zabezpieczył model przed zjawiskiem przeuczenia.

3 Podsumowanie i wnioski

Na nietkniętym zbiorze testowym ostateczny model bazowy osiągnął wyniki **ROC AUC = 0.7205** oraz **PR AUC = 0.4743**. Rezultaty te należy uznać za bardzo stabilny punkt wyjścia dla pojedynczego drzewa. W Kamieniu milowym 2 planowana jest budowa pełnego pipelineu oraz wykorzystanie znacznie silniejszych, co pozwoli wydatnie podnieść czułość systemu w celu minimalizacji strat banku z tytułu przeoczonych niewypłacalności.